LFM3：最强 2B 的多模态端侧全家桶

木牛流码
西安交通大学 生物医学工程硕士
关注他

收录于 • 端侧AI ›

1 人赞同了该文章 ›

2026 年 10 月 27 日，Liquid AI 发布 **LFM3**：六个约 2B 参数的模型，共用同一 backbone，覆盖文本、视觉（含视频）、音频、Omni，以及面向「一次前向出结构化决策」的 d1。厂商叙事里的关键词不是「再做一个小 LLM」，而是 **specialized intelligence**——按模态选型、单卡微调、部署到应用实际跑着的设备上。

下文依据 Liquid 官方博客、Hugging Face 同步博文与 LFM3-1.7B 模型卡整理。基准与端侧速度均为**官方自报**（及博客引用的 MacPaw 等合作方结果），不是本文独立复现；结论只谈到这些证据能支撑的边界。

端侧真正缺的，往往不是更大的通用模型

端侧智能的硬约束很具体：内存预算常以 GB 计、功耗与发热限制连续负载、数据最好不出设备、同时却要工具调用、长上下文代理，甚至看图听声。过去常见两条路：云端大模型（能力够，但延迟、成本与隐私另算），或端上塞一个「勉强能聊」的小模型（体积合适，却难扛 agent / 多模态）。

LFM3 的产品假设是第三条：**不要指望一个巨大通用模型包办端侧一切**；而是用同一套高效 backbone，切出文本 / 视觉 / 音频 / Omni / 决策几条线，让开发者按输入输出选实例，再用自己的数据做短微调。AMD、Ambarella、Qualcomm 在发布材料中的表态，也落在「AI PC / 边缘多负载 / Snapdragon 设备上的本地体验」这一侧，而不是云端竞技场。

若关心的是「这个系列能不能进手机、笔记本、Orin、NPU」，优先看三件事：体积与 KV 是否吃得消、agent / 工具链路是否够用、开源推理栈能不能当天跑起来。

六个约 2B：同一底座上的模态分工

第一批发布全部从 **LFM3-1.7B-Base** 分支，参数量落在约 2B 档：

模型	输入	输出	角色
LFM3-1.7B	文本	文本	本地 agent、工具调用、结构化输出；256K 上下文
LFM3-VL-2B	文本 / 图 / 视频	文本	视觉理解与具身相关能力；系列首次视频输入
LFM3-Audio-2B	文本 / 音频	文本 / 语音	语音对话、18 语 ASR/TTS、音频理解与工具调用
LFM3-Omni-2B	文本 / 图 / 视频 / 音频	文本 / 语音	看听说一体；口语问图、音视频联合推理
d1-2B	文本 / 图 / 视频	带校准概率的结构化答案	单次前向多问题决策（非长文生成）
d1-Omni-2B	上列 + 音频	同上	语音也可提问；保留大部分书面准确率

大家都在搜 换一换
10元快剪正席卷理发行业 387 万 热
网传九寨沟老人插队被劝阻... 387 万 新
赴港看演唱会女孩全家低保... 387 万 新
美国中期选举 387 万 新
美国邮轮终身旅居乘客被赶... 387 万 热
网传offer8垫钱姐论文造假... 387 万 热
警方通报网约车被狂欢人群... 387 万 热
清华毕业生UCL留学疑遭电... 387 万 新
将有两名中国人登陆月球 386 万
新华社追问国乒男队怎么了 302 万 热



▲ 赞同 1 ▼ 添加评论 1 喜欢 分享 申请转载 ···

成」还是「决策」。

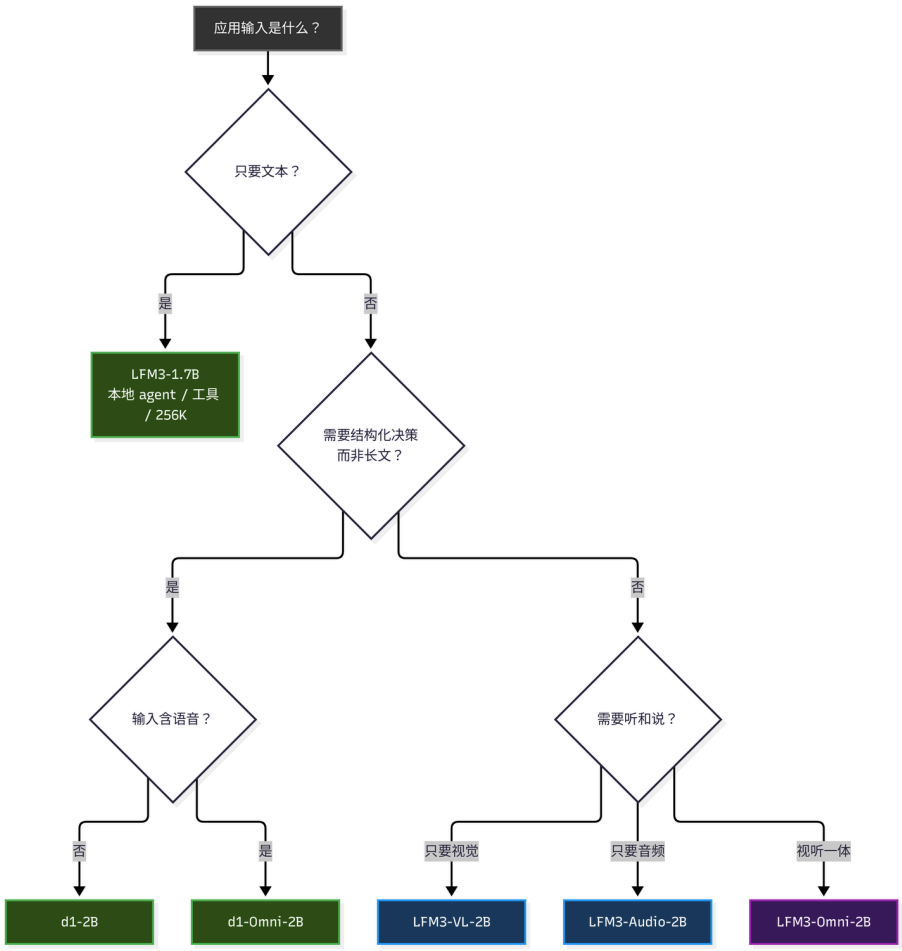


图 1：按输入与任务类型选择 LFM3 实例（示意）

HF 博文中的训练分支图把「共用 Base → 分模态 mid-train / SFT⁺ / RL → 决策模型再 SFT」画得更完整，如图 2 所示。文本线走 SFT → Mixed RL⁺ → MOPD⁺ → Agentic RL；视觉 / 音频 / Omni 各自 mid-train 后再汇合到对应实例，d1 再挂在 VL / Omni 之后。

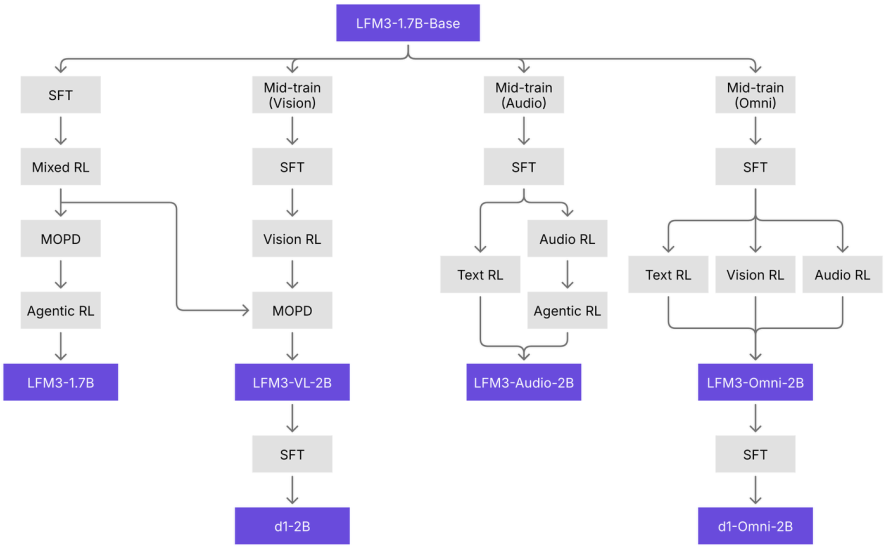


图 2：LFM3 从 Base 分支到六模型的训练路径（Liquid / HF 原图）

对端侧落地，这张图比「又多了几个 checkpoint」更有用：**模态能力被做成可替换组件**，设备不必常驻一个全模态巨兽。

LFM2 已用「短卷积 + 注意力」混合证明可以在设备上又快又够用，架构本身硬件在环搜索。LFM3 把搜索范围扩到 **14** 种设备与后端组合（含 Galaxy S26 Ultra、OnePlus 15、树莓派 5、M4 Max、Ryzen AI、云端 Arm/x86 CPU、GPU、以及 Qualcomm Hexagon NPU），目标明确偏向 **agentic：每参数更高能力，长上下文仍要快。**

24 层的算子配比是官方给出的核心数字：

13 层 gated short convolution⁺（卷积核从 LFM2 的 3 提到 **7**）

5 层 sliding-window attention⁺（窗口 **256**）

6 层 global attention

另有 head-wise gated attention（便于削弱伤害量化的激活 outlier⁺）、全局注意力上的 Partial RoPE、以及 Sandwich norm。词表仍为 **128K**。HF 博文中的骨干示意图如图 3 所示：左侧是 Embedding → 24 层（Sequence Block + SwiGLU FFN，均 sandwich norm）→ 输出；右侧展开 gated short conv 与 gated GQA；底部用 C / S / F 标出层模式。

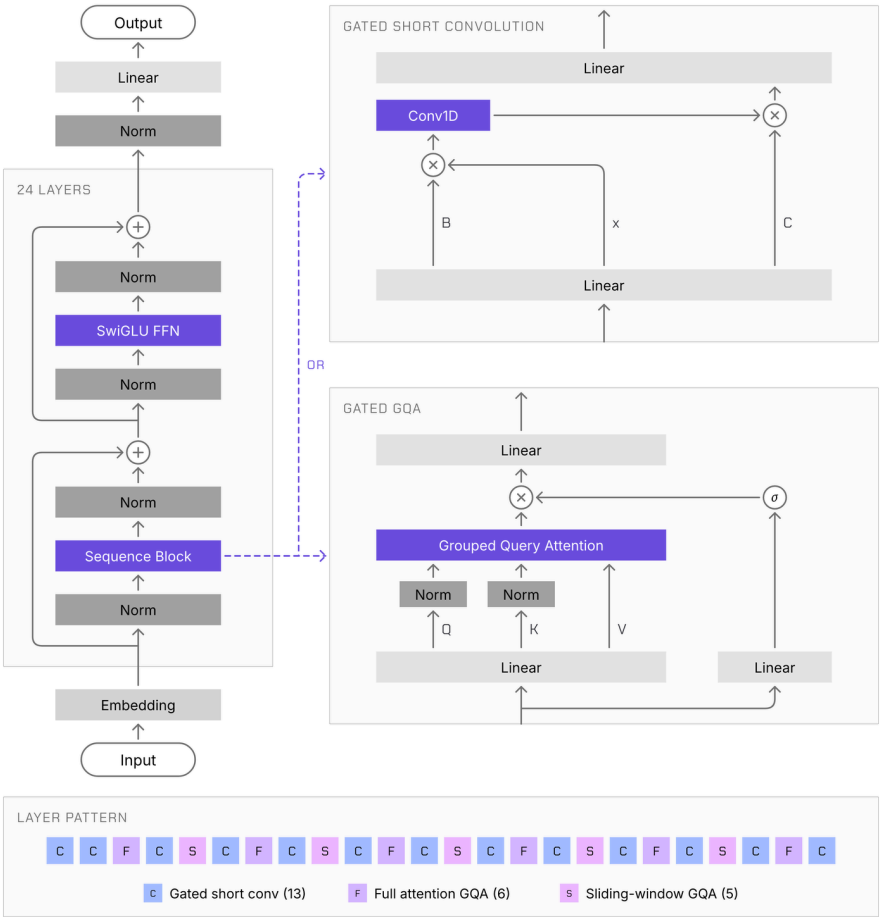


图 3：LFM3-1.7B backbone 与层模式（Liquid / HF 原图）

预训练总量 **22T** tokens；最后 **3.5T** 为 mid-training⁺，提高质量数据占比与 agentic / tool 轨迹，并把上下文拉到 **256K**。官方称：短 prompt 上每参数大致对齐 LFM2-1.2B；**8K 上下文时大约快 25%。**

对端侧更要紧的是取舍本身：**用更多卷积与 SWA 压住长上下文成本，用有限全局注意力与门控保住表达力与可量化性。**手机 / NPU 上的代理式多轮与工具轨迹，吃的就是这套预算。

文本线证据：agent 向指标亮眼，

模型卡也写明边界：适合本地 agent、工具、结构化输出与领域微调；知识密集任务宜配合检索；**不推荐**当作复杂 agentic coding / 复杂多步推理主力。

下表摘录官方对比中与端侧代理更相关的几行（完整表见博客 / 模型卡；服务端评测多为 vLLM BF16，口径以原文为准）：

基准	LFM3-1.7B	LFM2.5-2.6B	Qwen3.5-9B
LiveClaw	45.60	14.70	35.77
WebArena-Verified	38.42	3.02	28.94
AutomationBench	41.29	0.94	15.10
BFCL V4	71.39	55.89	62.83
ToolSandbox	80.36	78.04	76.41
IFBench	73.03	60.48	48.84
SWE-bench Verified（OpenCode）	43.40	18.00	51.20
GPQA Diamond	63.37	57.78	80.40
表内 Average	49.37	31.55	47.24

在 **厂商这张表** 上：相对自家 2.6B 前代，agent / 自动化类分数跳变明显；相对 9B 级 Qwen3.5，浏览器与商务自动化、部分工具调用并不吃亏，但 SWE-bench 与 GPQA 仍显示 **体量优势还在。**官方也写：搜索能把 Humanity's Last Exam（with tools）分数几乎翻倍——端侧部署若缺检索，不要把「小模型平均分」误读成「百科全书」。

MacPaw 工程师在博客中的对比更贴近「真机代理」：65 个 macOS 日常 agent 任务上，LFM3-1.7B 对 Qwen3.5-2B，任务成功率 **64% vs 48%**，每任务 token 少 **58%**，卡住比例 **不到 1% vs 15%。**这是单一机构、特定任务集上的结果，但方向与表内 agent 指标一致：**更小的模型可以在真实桌面代理里更稳、更省 token。**

体积、速度、KV：端侧能不能装下

官方给出的产品数字：

文本模型 **4-bit 约 1 GB**

llama.cpp、**Q4_0**、**32K** 上下文时，在其列出的三台设备上 decode 比次快模型快约 **1.8–2.8×**，内存最低；模型卡写 prefill 至少约 **2.5×**

128K 上下文 KV：LFM3 约 **1.6 GB**，对比表中 Qwen3.5-4B 约 **4.3 GB**、MiniCPM5-2B 约 **5.6 GB**

他们还给出服务端数字：B300 + SGLang BF16、1024 并发约 **36 亿 token/天。**对端侧读者，它只说明架构在高并发下也不拖；装机清单仍看 **1 GB 级权重 + 更瘦的 KV。**

推理接法方面，模型卡列出：Transformers / vLLM / SGLang（含 FP8、NVFP4）、**GGUF（llama.cpp / Ollama / LM Studio）**、**MLX**、ONNX；并写明 day-0 面向 Apple、AMD、NVIDIA、Qualcomm 等。端侧工程上，这意味着可以按芯片选栈，而不是卡在单一专有 runtime。

多模态与决策：同一故事的另外两章

视觉 LFM3-VL-2B（约 1.9B）在官方 62 项视觉基准平均 **71.4**（前代 LFM2.5-VL-3B 为 57.6），并称对齐更大的 Gemma 4 12B 量级。自研 **164M** vision encoder 相对旧 SigLIP2 路线宣称约 **3×** 更少算力；视频将成
力，往往比「再堆几个点的 VQA」更

的本地、低延迟与隐私。

Omni（约 2.2B）把看听说收进一个实例，官方举例包括「看手写题口语答」「随身平板问所见」「车载画面 + 驾驶员语音」。Daily-Omni 等音视频联合基准上，他们给出高于部分 7B 级 Omni 对比项的分数——仍属自报，但产品形态对「不想在端上串四个模型」的人更直接。

d1 换了一种输出方式：给情境 + 问题列表，**一次前向**给出带校准概率的答案，并扩展 Point / Read / Estimate / Pick 等类型。工单分流、单据抽取、界面元素定位这类「要结构不要散文」的负载，比生成后再正则解析更贴端侧控制面。d1-2B 相对 d1-3B 参数少约三分之一，官方 Decision / Imajev 等套件分数仍上升；Omni 版口语提问相对书面，DecisionBench 从 83.4 到 78.2，降幅有限。

「可专业化」比榜单更贴端侧 SOP

发布材料里，风机叶片缺陷与机器人三条线，用来证明 **短微调能把通用小模型变成窄域专家**，并且专家还能留在设备上。

风机叶片：约 3000 张公开图，SFT + GRPO，单 A100 数小时。基座与 GPT-6 Luna 对缺陷类型识别均不足 10%；微调后分类约 **67%**，检测 F1 从 **0.003 到 0.11**（对比项 GPT-6 Luna 约 0.01）。这是窄域、有标注、可复现流程的例子，不是「小模型全面超越前沿闭源」。

机器人：编排用 rank-32 LoRA、约 4 万样本、单 MI325X 约 6 GPU 小时；导航在严格连续控制设定下 R2R **53%** / RxR **43%**，Orin 上 TensorRT FP16 轨迹更新 **>2.5 Hz**；操作 VLA 跨 15 具身，LIBERO 四套平均成功率 **96.2%**，Orin 上动作块 **<50 ms**。

HF 还给出文本 / 视觉 / 音频 / Omni 的 Colab 微调笔记本（SFT、DPO、GRPO、CPT 等）。端侧团队可执行的闭环如图 4 所示：



图 4：端侧落地闭环——选型、单卡微调、再压测上设备

局限与判断

可以收成四点：

LFM3 的主场是「可部署的专业化」，不是「用 2B 吊打一切 9B+」。官方表与模型卡自己就承认 coding / 知识仍偏大体量；文本线明确建议检索补知识。

端侧吸引力来自系统数字：约 1 GB 的 4-bit 文本权重、更瘦的长上下文 KV、llama.cpp / MLX / Qualcomm 等 day-0 路径，以及按模态拆实例而不是强行全模态常驻。

多模态与 d1 扩展了端侧控制面：视频、低延迟语音、一次前向多决策，对应摄像头、车机、工单与 UI 自动化，而不仅是聊天框。

所有榜单与速度均为发布方口径；导入业务前仍需在目标 SoC、量化位宽与真实工具集上复测。Liquid 官网部分图表为前端渲染，本文未能内嵌那些交互图，但不影响上述可核验的文字数字。

若做端侧智能，LFM3 值得排进评估清单的理由很具体：它把「小、快、可微调、多模态分册、开源栈可接」捆成一套约 2B 产品线，并用 agent 向指标和设备向内存数字支撑——**专业化不必先搬去云端。**采不采用，仍取决于你的模态、标注能否撑起短微调，以及目标硬件上的实测，而不是发布日的平均分。

- [Liquid AI《Introducing LFM3》](liquid.ai/blog/lfm3)
- [HF Blog](huggingface.co/blog/Liq...)
- [LFM3-1.7B 模型卡](huggingface.co/LiquidAI...)
- [X 官宣](x.com/liquidai/status/2...)

送礼物

还没有人送礼物，鼓励一下作者吧

所属专栏 · 2026-11-01 11:08 更新

端侧AI

木牛流码 西安交通大学 生物医学工程硕士

3 篇内容 · 9 赞同

订阅

最热内容 · 腾讯开源 WeVisOne-VL：包揽「检测 + SAM + OCR」

编辑于 2026-11-01 09:40 · 湖北

端侧AI LLM VLM



12项 Harness权益全包，超量尊享 8.8折

多模态覆盖 18+旗舰模型、Harness 权益每月赠送、多 Agent 适配生产力全面扩容 查看详情

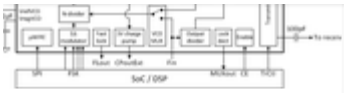
阿里云 的广告

理性发言，友善互动



还没有评论，发表第一个评论吧

推荐阅读



老板又要换器件啦——PLL怎么选?

彦小周



LDO和DCDC有什么异同?

软磨硬泡

汽车电子嵌入式软件分享。 内容提要 1 模块介绍 1.1 功能 1.2 组成 2 配置 2.1 DcmConfigSet 2.2 DcmGeneral 这篇文章我们主要讲解DCM(Diagnostic Communica...

刘SX



基于RAFT和LSM的分布式KV存储

Yice